

Ambang Keputusan, Bukan Arsitektur: Audit Ulang Deteksi Deepfake Audio pada Fake-or-Real

Naskah kerja penelitian. Seluruh angka pada dokumen ini dihitung ulang dari berkas hasil setiap kali dokumen dibangun.

Abstrak

Deteksi suara palsu buatan mesin biasanya dilaporkan dengan satu angka akurasi pada satu dataset. Penelitian ini mengaudit ulang cara pelaporan itu pada dataset Fake-or-Real dan menemukan bahwa angka tersebut sebagian besar mengukur hal lain daripada yang dikira. Pertama, riwayat kompresi berkas berkorelasi hampir sempurna dengan label pada data latih, yaitu 90,7 persen sampel palsu berasal dari berkas MP3 sementara tidak satu pun sampel asli, padahal pada data uji korelasi itu hilang sama sekali. Kedua, selisih besar yang biasa dikaitkan dengan cara pembagian data ternyata sebagian besar berasal dari ambang keputusan. Ketika model yang sama diuji pada partisi resmi, akurasi pada ambang tetap 0,5 jatuh ke 50,03 persen, sedangkan pada ambang yang disesuaikan dengan proporsi kelas ia tetap 92,56 persen. Daya pisah model tidak runtuh, hanya letak ambangnya yang bergeser. Ketiga, sebagian besar selisih antar konfigurasi yang selama ini dilaporkan tidak melampaui ragam antar inisialisasi acak. Dari enam perbandingan utama yang diuji dengan koreksi Holm-Bonferroni, hanya dua yang bertahan, dan keduanya berselisih puluhan poin persentase. Ragam antar inisialisasi pada 32 konfigurasi yang dijalankan minimal tiga kali memiliki median 1,80 poin persentase, cukup besar untuk menelan hampir seluruh selisih yang berukuran satu sampai empat poin. Penelitian ini melaporkan seluruh perbandingan, termasuk yang gagal, dan mencantumkan daftar klaim yang sempat ditulis lalu ditarik beserta alasannya.

Kata kunci: deteksi deepfake audio, Fake-or-Real, kalibrasi ambang, bias dataset, ragam antar inisialisasi, reproduksibilitas.

1. Pendahuluan

1.1 Latar belakang

Suara buatan mesin kini sulit dibedakan dari suara manusia oleh telinga biasa. Sistem text-to-speech komersial yang beredar pada 2025 dan 2026 menghasilkan ucapan yang wajar, dan penyalahgunaannya untuk penipuan sudah terjadi. Karena itu penelitian tentang pendeteksi otomatis berkembang cepat [1, 2]. Rangkaian tantangan ASVspoof menjadi acuan utama bidang ini [3, 4, 5, 6], dan sejumlah dataset lain melengkapinya, di antaranya Fake-or-Real [7], In-the-Wild [8], dan SpoofCeleb [9].

Fake-or-Real dipakai luas karena sederhana. Ia berisi ucapan asli dan ucapan buatan yang sudah dipotong menjadi potongan pendek, dan sudah menyediakan pembagian latih, validasi, dan uji secara resmi. Akurasi yang dilaporkan di atasnya sering berada di atas sembilan puluh persen, sehingga masalahnya tampak hampir selesai.

Kesan itu keliru, dan bidang ini sudah beberapa kali menemukan sebabnya. Model dapat mencapai angka tinggi dengan mempelajari isyarat yang tidak ada hubungannya dengan sintesis suara. Pada ASVspoof 2019 ditemukan bahwa panjang keheningan di awal berkas berbeda sistematis antara kelas asli dan kelas palsu [10]. Fenomena umumnya dikenal sebagai pembelajaran jalan pintas [11] dan sebagai bias dataset [12]. Ketika isyarat jalan pintas itu hilang, angka tinggi tadi ikut hilang [8, 13].

1.2 Celah yang dituju

Tiga hal jarang dikerjakan sekaligus dalam satu penelitian pada dataset ini. Pertama, memeriksa apakah dataset itu sendiri memuat isyarat jalan pintas, bukan hanya mengukur akurasi di atasnya. Kedua, memisahkan berapa bagian dari selisih yang dilaporkan berasal dari daya pisah model dan berapa bagian berasal dari letak ambang keputusan, sebab kedua hal itu gagal dengan cara yang sangat berbeda [14, 15]. Ketiga, menjalankan tiap konfigurasi lebih dari sekali dan melaporkan ragam antar inisialisasi acak, sebab tanpa itu tidak ada dasar untuk menyatakan satu konfigurasi lebih baik daripada yang lain [16].

1.3 Kontribusi

1. Audit provenance codec pada Fake-or-Real yang menunjukkan bahwa riwayat kompresi berkas berkorelasi hampir sempurna dengan label pada partisi latih dan validasi, lalu hilang sama sekali pada partisi uji. Perhitungannya hanya membaca nama berkas dan label, tanpa model dan tanpa keacakan, sehingga tidak memiliki ragam.
2. Pemecahan selisih antar protokol menjadi tiga sebab yang terukur terpisah, yaitu ambang keputusan, tingkat kematangan pelatihan, dan protokol pembagian data itu sendiri. Sebab yang selama ini dianggap utama ternyata menyumbang paling sedikit.
3. Matriks arsitektur terhadap perlakuan encoder yang menunjukkan bahwa arah pengaruh membekukan atau melatih encoder berbeda antar arsitektur, sehingga penyeragaman keputusan itu di muka merugikan sebagian arsitektur.
4. Pengujian statistik atas seluruh perbandingan utama dengan koreksi untuk banyaknya hipotesis, disertai laporan terbuka tentang perbandingan mana yang gagal.
5. Daftar klaim yang ditarik. Tiga belas pernyataan yang sempat ditulis pada tahap awal penelitian ini tidak bertahan setelah diuji ulang, dan seluruhnya dicantumkan beserta alasan penarikannya.

1.4 Cara membaca naskah ini

Bagian 2 meringkas karya terkait. Bagian 3 menjelaskan data dan metode, termasuk prosedur statistik dan pengaman yang dipasang terhadap kekeliruan penulisnya sendiri. Bagian 4 memuat hasil tanpa tafsir. Bagian 5 menafsirkannya. Bagian 6 mendaftar ancaman terhadap validitas. Bagian 7 memuat klaim yang ditarik. Bagian 8 menutup.

2. Karya terkait

2.1 Dataset dan protokol

Fake-or-Real disusun oleh Reimao dan Tzerpos [7] dari sekitar 87.000 ucapan buatan dan 111.000 ucapan asli, lalu diterbitkan dalam beberapa varian. Penelitian ini memakai varian for-2sec, yaitu potongan dua detik. In-the-Wild dikumpulkan dari podcast dan pidato tokoh publik dan dipakai sebagai uji di luar domain [8]. Rangkaian ASVspoof menyediakan protokol evaluasi yang jauh lebih ketat, termasuk pemisahan pembicara dan kondisi rekaman, serta metrik yang disepakati bersama [4, 17]. Tantangan lain seperti ADD 2022 menambah ragam serangan [18]. Sebuah analisis lanjutan mempertanyakan apakah kesulitan pada data di luar domain berasal dari serangan yang lebih sulit atau semata dari perbedaan domain [19], dan ini persis pemisahan yang juga dituju naskah ini.

Praktik pembagian data pada Fake-or-Real beragam, dan perbedaannya penting. Satu penelitian pembandingan memakai partisi resmi yang pembicaranya tidak beririsan antar partisi dan melaporkan akurasi sekitar 93 persen dengan mesin vektor pendukung klasik [20]. Penelitian lain memakai pembagian acak 80 banding 20 atas sebagian data dan melaporkan 94,7 persen dengan gabungan

jaringan konvolusi dan LSTM [21]. Penelitian ketiga melaporkan 94,47 persen tanpa menyebut protokolnya di abstrak [22], sehingga protokolnya tidak dapat dikutip di sini. Karena kedua angka pertama diperoleh pada protokol yang berbeda, keduanya tidak dapat dibandingkan langsung, dan ini persis persoalan yang hendak dibuka penelitian ini.

2.2 Arsitektur

Pendekatan yang kini lazim memakai model dasar swa-selia sebagai penyari depan. wav2vec 2.0 [23], HuBERT [24], dan WavLM [25] dilatih pada ucapan tanpa label dalam jumlah besar, lalu keluarannya diolah oleh bagian belakang yang lebih kecil. Tak dan rekan menunjukkan bahwa penyari depan wav2vec 2.0 yang disetel ulang mencapai kesalahan terendah pada ASVspoof 2021 [26]. Bagian belakang yang banyak dipakai antara lain RawNet2 [27], AASIST [28], dan yang lebih baru Nes2Net [29] yang dirancang khusus untuk keluaran berdimensi tinggi dari model dasar. Audio Spectrogram Transformer [30] mewakili jalur berbeda, yaitu pra-latih terselia pada label suara umum. Penggabungan statistik dengan perhatian [31] dipakai untuk meringkas urutan menjadi satu vektor. Pengembangan mutakhir bergerak ke dua arah, yaitu memperbaiki efisiensi bagian belakang [32] dan menggabungkan beberapa model WavLM menjadi satu keputusan [33].

2.3 Augmentasi

RawBoost [34] menambahkan derau konvolutif dan aditif langsung pada gelombang mentah untuk menirukan ragam saluran telepon, tanpa memerlukan rekaman derau dari luar. Augmentasi terbukti menjadi salah satu penentu terbesar kinerja lintas domain pada ASVspoof 2021 [26]. Namun augmentasi juga dapat memperburuk, terutama bila data tambahan membawa bias yang berbeda dari data asalnya [35].

2.4 Metrik dan kalibrasi

Bidang ini hampir selalu melaporkan equal error rate. Metrik itu dihitung pada ambang terbaik yang dipilih setelah label uji diketahui, sehingga ia mengukur daya pisah, bukan kesiapan pakai. Sebuah audit terbaru [14] menunjukkan akibatnya dengan tajam: sebuah pendeteksi mutakhir mencapai equal error rate 0,21 persen di dalam domain, tetapi ketika ambang yang dikalibrasi pada domain itu dipindahkan ke In-the-Wild, setengah total kesalahannya menjadi 39,5 persen dan 78,7 persen ucapan asli ditolak. Temuan itu sejalan dengan hasil bagian 4.2 naskah ini, yang diperoleh secara terpisah pada dataset yang berbeda. Kalibrasi keluaran jaringan saraf modern memang diketahui buruk secara umum [15]. Pengujian bergaya penetrasi terhadap pendeteksi yang sudah beredar juga menemukan bahwa kinerja yang dilaporkan sering tidak bertahan di luar kondisi pengujiannya [36].

2.5 Bias dataset

Bukti paling dekat dengan temuan pertama naskah ini datang dari analisis bias pada anti-spoofing [10]. Penelitian itu menerapkan kompresi MP3 hanya pada data asli dan memperoleh equal error rate nol persen, lalu menerapkannya hanya pada data palsu di sisi uji dan memperoleh kesalahan di atas 99 persen, yaitu pembalikan label yang lengkap. Percobaan itu memperlihatkan bahwa riwayat pengodean berkas dapat sepenuhnya menggantikan isyarat sintesis. Audit pada bagian 4.1 naskah ini menemukan ketidakseimbangan serupa yang sudah ada di dalam Fake-or-Real apa adanya, tanpa campur tangan siapa pun. Karya lain menelusuri jejak codec neural sebagai isyarat tersendiri [37] dan bias bahasa sebagai sumber jalan pintas lain [38].

2.6 Ragam dan reproduksibilitas

Bouthillier dan rekan menunjukkan bahwa ragam yang berasal dari inisialisasi, pengambilan sampel data, dan pemilihan hyperparameter cukup besar untuk mengubah kesimpulan pada tolok ukur pembelajaran mesin [16]. Dalam bidang ini, laporan yang menyertakan simpangan baku atas beberapa

inisialisasi masih jarang. Ketiga penelitian pembandingan pada bagian 2.1 tidak mencantumkan. Persoalan menguji banyak hipotesis sekaligus sudah lama dikenal [39], dan koreksinya tersedia [40, 41], termasuk anjuran khusus untuk membandingkan pengklasifikasi [42]. Di luar bidang suara, pengujian ulang tolak ukur yang sudah mapan dengan data uji yang benar-benar baru memperlihatkan bahwa peringkat metode dapat berubah begitu data ujinya diganti [43].

3. Data dan metode

3.1 Dataset

Penelitian ini memakai Fake-or-Real varian for-2sec [7], yang diunduh dari sumber resminya. Seluruh 17.870 berkas diperiksa dan seluruhnya berlaju cuplik 16.000 Hz tanpa kecuali. Partisi resmi berisi 13.956 berkas latih, 2.826 berkas validasi, dan 1.088 berkas uji. Selain itu dipakai beberapa kumpulan uji tambahan yang tidak pernah dilihat saat pelatihan, yaitu In-the-Wild [8], versi rekam ulang dari Fake-or-Real, ucapan buatan dari empat belas sistem text-to-speech yang mencakup empat generasi teknologi, dan derau dari korpus DEMAND [44].

3.2 Protokol pembagian data

Dua protokol dibandingkan. Protokol pertama adalah partisi resmi yang disediakan dataset, yang pembicaraanya tidak beririsan antar partisi. Protokol kedua adalah pembagian acak 60, 20, dan 20 persen atas gabungan seluruh berkas, tanpa memperhatikan pembicara. Protokol kedua sengaja dipilih karena ia mewakili praktik yang dipakai sebagian penelitian terbitan [21], sehingga perbandingannya menjadi bermakna.

3.3 Arsitektur yang diuji

Tujuh arsitektur diuji. Tiga di antaranya memakai model dasar swa-selia sebagai penyari depan, yaitu WavLM Large [25], HuBERT Large [24], dan Wav2Vec2 Base [23]. Satu memakai pra-latih terselia, yaitu AST [30]. Satu memakai bagian belakang Nes2Net di atas penyari depan swa-selia [29]. Dua sisanya adalah dasar pembandingan yang dilatih dari awal, yaitu jaringan konvolusi dengan penggabungan statistik memperhatikan [31] dan jaringan konvolusi dengan LSTM dua arah. Keluaran tiap lapisan model dasar digabungkan dengan bobot yang ikut dilatih, sehingga model dapat memilih sendiri lapisan mana yang berguna.

3.4 Prosedur pelatihan

Pelatihan memakai optimasi AdamW dengan penghentian dini berdasarkan equal error rate pada data validasi. Ukuran batch dan jumlah epoch dicatat pada nama tiap run, dan dua run hanya dibandingkan bila keduanya memakai konfigurasi yang sama. Aturan ini terdengar sepele tetapi justru menjadi sumber kekeliruan terbesar dalam penelitian ini, dan penanganannya dijelaskan pada bagian 3.7. Tiap sel dijalankan dengan beberapa inisialisasi acak yang berbeda, paling sedikit tiga dan paling banyak delapan untuk sel yang paling menentukan.

3.5 Metrik

Tiga metrik dilaporkan. Yang pertama adalah akurasi pada ambang tetap 0,5, yaitu ambang yang tersirat bila keluaran model dipakai apa adanya. Yang kedua adalah akurasi pada ambang prior-matched, yaitu ambang yang dipilih sehingga proporsi sampel yang diberi label palsu sama dengan proporsi palsu yang sebenarnya. Ambang ini tidak memerlukan label satu per satu, hanya proporsi kelas, sehingga masih dapat dihitung dalam pemakaian nyata selama proporsi kelas diketahui. Yang ketiga adalah area di bawah kurva dan equal error rate, keduanya tidak bergantung ambang.

Pemisahan ini penting dan menjadi tulang punggung seluruh naskah. Bila akurasi jatuh sementara area di bawah kurva bertahan, yang rusak adalah kalibrasi ambang. Bila keduanya jatuh bersama, yang rusak adalah daya pisah model. Kedua kerusakan itu memerlukan perbaikan yang sama sekali berbeda, dan melaporkan hanya satu angka akurasi membuat keduanya tampak sama.

3.6 Prosedur statistik

Tiap perbandingan dua konfigurasi diuji dengan uji t Welch [45], yang tidak mengandaikan ragam kedua kelompok sama. Karena beberapa hipotesis diuji sekaligus, nilai p mentah tidak dapat dibaca apa adanya. Menguji enam hipotesis pada ambang 0,05 memberi peluang sekitar 26 persen untuk memperoleh setidaknya satu hasil yang tampak bermakna semata karena kebetulan. Karena itu koreksi Holm-Bonferroni diterapkan pada tiap keluarga perbandingan [40], dan keputusan diambil dari nilai p terkoreksi. Untuk korelasi dipakai uji permutasi, karena ukuran sampel terlalu kecil untuk mengandalkan sebaran teoretis. Perlu ditekankan bahwa nilai p yang besar pada ukuran sampel sekecil ini berarti belum terbukti berbeda, bukan terbukti sama.

3.7 Pengaman terhadap kekeliruan penulisnya sendiri

Penelitian ini menemukan tujuh kekeliruan pada pekerjaannya sendiri, dan semuanya berjenis sama: dua run dengan konfigurasi berbeda dibandingkan seolah-olah hanya satu variabel yang berbeda. Akibatnya, ragam antar konfigurasi dilaporkan sebagai ragam antar inisialisasi acak. Kekeliruan semacam itu tidak dapat dicegah dengan kehati-hatian saja, sebab ia justru muncul pada saat penulis merasa hati-hati.

Karena itu dipasang dua pengaman yang bekerja tanpa bergantung pada ingatan penulis. Pengaman pertama adalah pemeriksa otomatis yang mengelompokkan seluruh run menurut arsitektur, protokol, dan augmentasi, lalu menolak menyinkronkan hasil apabila ada kelompok yang memuat lebih dari satu konfigurasi pelatihan tanpa pengecualian yang tercatat. Pengaman kedua adalah aturan bahwa setiap angka pada prosa harus dihitung ulang dari berkas hasil saat dokumen dibangun, bukan diketik. Naskah yang sedang Anda baca tunduk pada aturan itu. Praktik semacam ini sejalan dengan anjuran pra-registrasi [46], walaupun bentuknya di sini lebih sederhana.


4. Hasil

4.1 Riwayat kompresi berkorelasi dengan label, tetapi hanya pada sebagian partisi

Perhitungan pertama tidak melibatkan model sama sekali. Ia hanya membaca nama berkas dan label pada manifest, lalu menghitung berapa persen berkas tiap kelas yang berasal dari sumber MP3. Karena tidak ada model dan tidak ada keacakan, hasilnya tidak memiliki ragam antar inisialisasi dan tidak memerlukan pengujian statistik.

Tabel 1. Riwayat kompresi menurut partisi dan kelas. Dihitung langsung dari nama berkas pada manifest.

Partisi	Kelas	Jumlah berkas	Berasal MP3	Persen
testing	asli	544	0	0,0
testing	palsu	544	0	0,0
training	asli	6.978	0	0,0
training	palsu	6.978	6.326	90,7
validation	asli	1.413	0	0,0
validation	palsu	1.413	1.266	89,6



Perhitungan langsung dari nama berkas pada manifest. Tidak melibatkan model, pelatihan, maupun keacakan.

Gambar 1. Riwayat kompresi berkorelasi hampir sempurna dengan label pada partisi latih dan validasi, yaitu 90,7 dan 89,6 persen sampel palsu berasal dari MP3 sementara tidak satu pun sampel asli. Pada partisi uji korelasi itu hilang sama sekali. Model yang mempelajari jejak kompresi karena itu akan tampak sangat baik pada data latih dan validasi, lalu kehilangan seluruh isyaratnya pada data uji.

Akibatnya langsung. Sebuah model yang mempelajari jejak kompresi akan memperoleh isyarat yang hampir sempurna pada dua partisi pertama, lalu kehilangan isyarat itu seluruhnya pada partisi ketiga. Yang dipelajarinya bukan jejak sintesis melainkan riwayat berkas, dan riwayat itu berkorelasi dengan label hanya pada sebagian partisi.

4.2 Sebagian besar selisih berasal dari ambang keputusan


Selisih besar antara split acak dan partisi resmi sering dibaca sebagai bukti bahwa protokol pembagian data menentukan hasil. Bagian ini memecahnya menjadi tiga sebab yang diukur terpisah. Dua konfigurasi pertama memakai model, data, dan hyperparameter yang sama persis, sehingga hanya protokolnya yang berbeda.

Tabel 2. Dua protokol pada model dan hyperparameter yang identik. Angka dalam kurung adalah simpangan baku antar inisialisasi.

Konfigurasi	n	Akurasi @0,5	Akurasi @prior	AUC	EER
CNN + ASP, split acak 60/20/20	3	99,93 (0,07)	99,48 (0,47)	100,00 (0,00)	0,03 (0,03)
CNN + ASP, partisi resmi FoR	3	50,03 (0,05)	92,56 (3,72)	97,56 (1,74)	7,38 (3,81)

Pada ambang tetap 0,5, selisihnya 49,90 poin persentase. Pada ambang prior-matched, selisihnya menyusut menjadi 6,92 poin. Area di bawah kurva pada partisi resmi tetap 97,56 persen. Artinya model masih dapat memisahkan kedua kelas dengan sangat baik. Yang berpindah hanyalah letak ambang yang tepat.

Sebagian besar selisih berasal dari ambang keputusan, bukan dari protokol pembagian data




Gambar 2. Panel kiri memperlihatkan akurasi kedua protokol pada dua ambang. Garis putus-putus adalah ambang tetap 0,5 dan garis penuh adalah ambang prior-matched. Jarak tegak antara keduanya pada partisi resmi, sebesar 42,52 poin, seluruhnya adalah kesalahan kalibrasi. Panel kanan memecah selisih total menjadi tiga sebab. Sebab yang selama ini dianggap utama, yaitu protokol pembagian data, justru menyumbang paling sedikit.

Tabel 3. Pemecahan selisih menjadi tiga sebab yang diukur terpisah.

Sebab	Sumbangan	Bacaan
Ambang keputusan	42,52 poin	Ambang 0,5 tidak lagi cocok dengan sebaran skor pada partisi resmi.
Model kurang terlatih	20,68 poin	Versi awal dilatih lebih singkat daripada versi pembanding.
Protokol pembagian data	6,92 poin	Sisa yang benar-benar dapat diatribusikan kepada protokol.

Pola yang sama muncul pada percobaan yang sepenuhnya berbeda. Ketika derau dari korpus DEMAND ditambahkan pada data uji dengan berbagai tingkat, area di bawah kurva WavLM turun perlahan sementara akurasi pada ambang yang dibekukan dari kondisi bersih turun jauh lebih cepat. Dua percobaan yang tidak berhubungan menunjukkan mekanisme yang satu dan sama.

Dua eksperimen terpisah, satu mekanisme: daya pisah bertahan sementara ambang bergeser



Gambar 3. Panel kiri adalah WavLM di bawah derau. Garis hitam adalah area di bawah kurva, yang tidak bergantung ambang. Bidang bersisir adalah selisih antara memakai ambang yang disesuaikan dan ambang yang dibekukan dari kondisi bersih. Panel kanan adalah CNN + ASP lintas protokol pada sumbu yang sama. Pada kedua panel, daya pisah bertahan sementara ambangnya bergeser.

4.3 Tidak ada satu perlakuan encoder yang benar untuk semua arsitektur


Konfigurasi yang diusulkan di awal penelitian ini menetapkan satu laju belajar seragam 0,001 untuk seluruh arsitektur. Bagian ini menguji keputusan tersebut dengan menjaga seluruh hal lain tetap dan

hanya mengubah perlakuan terhadap encoder.

Tabel 4. Matriks arsitektur terhadap perlakuan encoder pada partisi resmi, ambang prior-matched. Tiga baris pertama tiap arsitektur memakai paket rekayasa yang sama persis, sehingga perbandingannya bersifat satu variabel.

Arsitektur	Perlakuan encoder	n	Akurasi	AUC	EER
AST	Encoder dibekukan	3	89,15 (3,49)	0,9540	10,81 (3,54)
AST	Encoder dilatih, laju wajar per model	3	93,38 (1,85)	0,9811	6,68 (1,75)
AST	Encoder dilatih, laju 0,001	1	88,51	0,9513	11,49
AST	Konfigurasi proposal, laju 0,001 seragam	3	93,57 (1,75)	0,9824	6,50 (1,81)
WavLM Large	Encoder dibekukan	5	98,36 (0,63)	0,9985	1,65 (0,61)
WavLM Large	Encoder dilatih, laju wajar per model	3	97,30 (1,71)	0,9959	2,70 (1,63)
WavLM Large	Encoder dilatih, laju 0,001	1	80,06	0,8963	19,94
WavLM Large	Konfigurasi proposal, laju 0,001 seragam	5	63,29 (4,19)	0,7096	36,73 (4,17)
HuBERT Large	Encoder dibekukan	3	94,67 (1,12)	0,9907	5,33 (1,12)
HuBERT Large	Encoder dilatih, laju wajar per model	5	96,19 (2,37)	0,9921	3,84 (2,38)
HuBERT Large	Encoder dilatih, laju 0,001	1	43,66	0,4837	55,97
HuBERT Large	Konfigurasi proposal, laju 0,001 seragam	5	51,64 (6,47)	0,5597	48,60 (6,58)

Arah pengaruh perlakuan encoder berbeda antar arsitektur, sehingga tidak ada satu pilihan yang benar untuk semuanya



Gambar 4. Arah pengaruh perlakuan encoder berbeda antar arsitektur. Pada AST, melatih encoder lebih baik daripada membekukannya. Pada WavLM Large, justru sebaliknya. Laju belajar seragam 0,001 yang diusulkan di awal berjalan wajar pada AST tetapi merusak kedua model swa-selia berukuran besar. Panjang batang galat menunjukkan bahwa sebagian selisih ini tidak dapat dipisahkan dari ragam antar inisialisasi, dan pengujiannya ada pada bagian 4.4.


Penjelasannya sederhana. Model swa-selia berukuran tiga ratus juta parameter yang dilatih pada ucapan tanpa label dalam jumlah besar akan kehilangan representasinya bila diperbarui dengan laju sebesar itu pada data yang jauh lebih kecil. AST yang berukuran delapan puluh enam juta parameter dan pra-latihnya terselia tidak mengalami hal yang sama. Keputusan membekukan atau melatih encoder karena itu harus ditetapkan per arsitektur menggunakan data validasi, bukan diseragamkan di muka.

4.4 Apa yang bertahan setelah ragam antar inisialisasi diukur

Bagian ini menguji enam perbandingan utama sekaligus dan menerapkan koreksi Holm-Bonferroni. Hasilnya terbelah bersih menjadi dua kelompok yang tidak saling berdekatan.

Tabel 5. Enam perbandingan utama pada partisi resmi, ambang prior-matched, uji t Welch dengan koreksi Holm-Bonferroni.

Perbandingan	n	Rerata A	Rerata B	Selisih	p mentah	p Holm	Bacaan
AST: encoder dilatih lawan dibekukan	3/3	93,38	89,15	+4,23	0,1597	0,6389	belum terbukti berbeda
AST: encoder dilatih lawan proposal	3/3	93,38	93,57	-0,18	0,9064	0,9064	belum terbukti berbeda
WavLM: encoder dibekukan lawan dilatih	5/3	98,36	97,30	+1,06	0,3964	0,7978	belum terbukti berbeda
HuBERT: encoder dilatih lawan dibekukan	5/3	96,19	94,67	+1,53	0,2659	0,7978	belum terbukti berbeda
WavLM: rekayasa lawan proposal	5/5	98,36	63,29	+35,07	< 0,0001	0,0002	melampaui ragam
HuBERT: rekayasa lawan proposal	5/5	96,19	51,64	+44,56	< 0,0001	0,0002	melampaui ragam




Gambar 5. Peta hutan enam perbandingan utama. Titik adalah selisih rerata dan bentangan adalah selang kepercayaan 95 persen. Perbandingan yang bentangannya memotong garis nol belum terbukti berbeda. Hanya dua yang bertahan, dan keduanya berselisih puluhan poin persentase.

Kelompok pertama adalah perbandingan antara konfigurasi proposal dan konfigurasi rekayasa pada kedua model swa-selia besar. Selisihnya berpuluh poin dan nilai p terkoreksinya jauh di bawah ambang. Perlu dicatat bahwa pada tahap sebelumnya, ketika tiap sel baru memiliki tiga inisialisasi, kedua perbandingan ini justru berhenti pada nilai p terkoreksi 0,0520, yaitu tepat di atas ambang. Penyebabnya bukan efek yang kecil melainkan derajat bebas yang sangat sedikit. Menambah inisialisasi keempat dan kelima menyelesaikannya.

Kelompok kedua adalah perbandingan antara membekukan dan melatih encoder. Selisihnya berada pada orde yang sama dengan simpangan bakunya sendiri, dan tidak satu pun terbukti berbeda meskipun sebagian sel sudah memiliki lima inisialisasi. Untuk kelompok ini, penelitian ini tidak berhak menyatakan bahwa satu perlakuan lebih baik daripada yang lain.

Empat dari enam efek yang diuji tidak melampaui ragam antar inisialisasi




Gambar 6. Panel atas adalah sebaran ragam antar inisialisasi pada 32 konfigurasi yang dijalankan minimal tiga kali, dengan median 1,80 poin persentase. Panel bawah menempatkan keenam efek yang diuji pada sumbu yang sama. Empat di antaranya jatuh pada wilayah tempat efek lebih kecil daripada ragam khas antar inisialisasi, dan keempatnya memang tidak lolos pengujian.

4.5 Ketahanan terhadap derau

Model diuji pada data uji yang dicampur derau dari korpus DEMAND [44], yang tidak dipakai sama sekali saat pelatihan. Rasio sinyal terhadap derau diturunkan bertahap dari kondisi bersih sampai minus lima desibel.

Tabel 6. Akurasi pada ambang prior-matched di bawah derau DEMAND.

Arsitektur dan augmentasi	bersih	20 dB	10 dB	5 dB	0 dB	-5 dB
wavlm [full]	98,6	98,0	98,0	97,5	95,5	89,2
hubert [full]	95,4	93,1	91,2	89,5	84,1	77,5
cnn_asp [full]	95,1	88,2	86,8	84,6	82,7	78,5
wavlm [codec]	96,4	92,6	89,4	86,6	76,2	66,2
cnn_asp [codec]	91,9	74,7	72,2	69,0	65,3	59,8
ast [codec]	86,4	76,5	68,2	65,7	61,9	57,1
hubert [codec]	97,1	92,6	87,0	75,2	61,0	54,0
wav2vec2 [codec]	90,7	84,7	75,3	67,2	60,4	57,8
cnnlstm [codec]	83,5	60,6	58,2	56,2	54,1	52,0



Gambar 7. Augmentasi penuh mempertahankan akurasi jauh lebih lama daripada augmentasi codec saja. Perhatikan bahwa urutan pada kondisi bersih tidak memperkirakan urutan pada kondisi berderau. Model yang hanya diaugmentasi codec bertumbangan lebih dahulu, dan sebagian di antaranya mendekati tebak acak pada minus lima desibel.


4.6 Generalisasi terhadap text-to-speech mutakhir

Model diuji pada ucapan buatan dari empat belas sistem text-to-speech yang mencakup empat generasi, dari era yang sezaman dengan Fake-or-Real sampai sistem komersial 2025 dan 2026. Ambang tiap model disamakan pada spesifisitas 95 persen memakai 1.500 berkas asli In-the-Wild sebagai acuan, sehingga perbandingan antar model bersifat adil.

Tabel 7. Recall pada text-to-speech komersial mutakhir, diukur pada spesifisitas 95 persen yang disamakan.

Arsitektur dan augmentasi	n	Recall TTS komersial 2025-2026
nes2net [full]	3	94,97 (5,34)
nes2net [fullbgrb]	3	93,67 (3,47)
nes2net [fullbg]	3	93,50 (4,77)
wavlm [fullbgrb]	3	92,69 (4,68)
wavlm [fullbg]	3	92,56 (2,15)
hubert [fullbg]	3	91,33 (4,04)
wavlm [full]	3	88,39 (7,29)
nes2net [fullrb]	3	87,64 (6,41)
hubert [full]	3	85,67 (6,11)
nes2net [soft]	3	80,94 (15,78)

Tidak ada pertukaran yang terbukti antara akurasi Fake-or-Real dan deteksi TTS mutakhir



$r = -0.042$ pada 10 konfigurasi. Uji permutasi 20.000 kali memberi $p = 0.905$.

Gambar 8. Tidak ada pertukaran yang terbukti antara akurasi pada Fake-or-Real dan kemampuan mendeteksi text-to-speech mutakhir. Baris diurutkan menurut akurasi Fake-or-Real. Bila pertukaran itu ada, penanda jingga akan bergeser berlawanan arah dengan penanda biru, dan itu tidak terjadi secara konsisten.


4.7 Model publik terkemuka pada data di luar domainnya

Sebagai pembanding luar, sebuah model pendeteksi yang tersedia untuk umum dan dilaporkan berkinerja tinggi diuji apa adanya pada partisi uji Fake-or-Real dan pada ucapan buatan komersial mutakhir.

Tabel 8. Model publik terkemuka pada TTS komersial 2025-2026. Pada partisi uji Fake-or-Real, model yang sama memperoleh akurasi 8,73 persen dan area di bawah kurva 2,33 persen.

Sistem TTS	n	Recall @0,5	Recall @ambang terkalibrasi FoR
Chatterbox	400	98,00	28,00
ElevenLabs-v3	400	99,75	57,25
Higgs-Audio-V2	400	100,00	79,25
OpenAI TTS-1 HD	400	99,25	45,75
f5-tts	400	82,25	6,75

Model publik terkemuka runtuh pada partisi uji Fake-or-Real, dan ambangnya sendiri yang merusak deteksi TTS mutakhir



Gambar 9. Panel kiri adalah kinerja pada partisi uji Fake-or-Real. Area di bawah kurva jauh di bawah lima puluh persen berarti urutan skornya terbalik, bukan sekadar acak. Panel kanan memperlihatkan bahwa pada text-to-speech komersial, model yang sama sebenarnya sangat baik pada ambang 0,5, tetapi kehilangan sebagian besar kemampuannya begitu ambangnya dikalibrasi pada Fake-or-Real. Sekali lagi, yang rusak adalah ambang, bukan daya pisah.

5. Pembahasan

Tiga hasil pada bagian 4 saling menopang menjadi satu pernyataan tunggal. Angka akurasi tunggal pada dataset tunggal tidak cukup untuk menilai pendeteksi suara palsu, sebab angka itu mencampur tiga hal yang gagal dengan cara berbeda: apa yang dipelajari model, seberapa baik ia memisahkan kedua kelas, dan di mana ambang keputusannya berada.

Temuan tentang riwayat kompresi menunjukkan masalah pertama. Sebuah model dapat memperoleh angka tinggi pada data latih dan validasi dengan mempelajari sesuatu yang bahkan bukan sifat suara, melainkan sifat berkas. Temuan ini bukan yang pertama dalam jenisnya. Panjang keheningan pada ASVspoof 2019 dan percobaan kompresi MP3 yang membalik label sepenuhnya [10] sudah menunjukkan pola yang sama. Yang ditambahkan di sini adalah bahwa ketidakseimbangan semacam itu sudah ada di dalam Fake-or-Real apa adanya, tanpa campur tangan siapa pun, dan bahwa ia hilang tepat pada partisi tempat model diuji.

Temuan tentang ambang menunjukkan masalah kedua dan ketiga sekaligus. Ketika akurasi jatuh dari sekitar sembilan puluh sembilan persen menjadi sekitar lima puluh persen sementara area di bawah kurva bertahan di atas sembilan puluh tujuh persen, yang terjadi bukan kegagalan model mengenali suara palsu, melainkan kegagalan menempatkan ambang. Perbedaannya besar dalam praktik. Kegagalan daya pisah menuntut model yang lebih baik. Kegagalan kalibrasi menuntut prosedur penetapan ambang, yang jauh lebih murah. Audit terbaru pada dataset yang sama sekali berbeda menemukan pola yang sama [14], dan kesesuaian dua penelitian independen ini memperkuat keduanya.

Temuan tentang ragam menunjukkan masalah yang lebih mendasar. Bila median simpangan baku antar inisialisasi adalah 1,80 poin persentase, maka seluruh selisih berukuran satu sampai tiga poin yang dilaporkan tanpa menjalankan ulang dengan inisialisasi berbeda tidak dapat dibedakan dari derau. Penelitian ini sendiri sempat menulis tiga belas klaim semacam itu sebelum menariknya. Tidak ada alasan untuk mengira penelitian lain kebal dari hal yang sama [16].

Konsekuensi praktisnya sempit tetapi jelas. Laporan kinerja pendeteksi suara palsu sebaiknya mencantumkan empat hal yang sekarang jarang ada sekaligus: protokol pembagian data secara eksplisit, metrik yang tidak bergantung ambang di samping akurasi, prosedur penetapan ambang yang dipakai, dan simpangan baku atas beberapa inisialisasi acak. Keempatnya tidak memerlukan metode baru, hanya kemauan melaporkan.

6. Ancaman terhadap validitas

Bagian ini mendaftar hal-hal yang dapat membuat kesimpulan di atas keliru, termasuk yang belum dapat diselesaikan.

Ancaman	Penjelasan	Penanganan
Ukuran sampel kecil	Tiap sel paling banyak memiliki delapan inisialisasi, dan sebagian besar hanya tiga. Uji t pada ukuran ini berdaya rendah.	Dilaporkan apa adanya. Nilai p besar dibaca sebagai belum terbukti berbeda, bukan terbukti sama.
Satu dataset utama	Sebagian besar hasil diperoleh pada satu varian satu dataset, sehingga belum tentu berlaku umum.	Kumpulan uji tambahan dipakai untuk pemeriksaan silang, tetapi ini tetap pembatas terbesar.
Ambang prior-matched memerlukan proporsi kelas	Ambang ini tidak memerlukan label satu per satu, tetapi tetap memerlukan proporsi kelas yang sebenarnya.	Dinyatakan terus terang. Ia bukan prosedur siap pakai untuk keadaan yang proporsi kelasnya tidak diketahui.
Perbandingan dengan penelitian lain tidak setara	Penelitian perbandingan memakai partisi dan bahkan laju cuplik yang berbeda dari yang dipakai di sini.	Perbandingan disajikan sebagai indikasi mekanisme, bukan sebagai perbandingan langsung.

Ancaman	Penjelasan	Penanganan
Pemilihan perbandingan yang diuji	Enam perbandingan utama dipilih oleh penulis, dan pemilihan itu sendiri dapat memihak.	Seluruh perbandingan yang dijalankan dilaporkan, termasuk yang gagal. Bagian 7 memuat yang ditarik.

7. Klaim yang ditarik

Bagian ini tidak lazim ada pada makalah, dan justru karena itu ia dicantumkan. Selama penelitian berlangsung, sejumlah pernyataan sempat ditulis lalu gugur setelah diuji ulang dengan inisialisasi tambahan atau setelah kekeliruan konfigurasi ditemukan. Mencantumkaninya mencegah pernyataan itu terpakai kembali tanpa sengaja, dan memberi pembaca ukuran tentang seberapa besar bagian dari hasil awal yang tidak bertahan.

Klaim yang ditarik	Alasan penarikan
Selisih akibat protokol pembagian data sekitar 50 poin	Menggabungkan tiga sebab. Setelah dipisah, protokol hanya menyumbang 6,92 poin dan tidak lolos pengujian.
Korelasi -0,542 antara akurasi Fake-or-Real dan recall TTS mutakhir	Dihitung ulang dengan pengelompokan yang benar menjadi mendekati nol, dan uji permutasi memberi nilai p jauh di atas ambang.
Korelasi -0,980 yang mendukung hipotesis ceiling	Dihitung atas tiga titik. Tiga titik hanya memiliki enam permutasi, sehingga nilai p terkecil yang mungkin adalah 0,33.
Band-gain memperbaiki recall TTS era 2019 sebesar sepuluh poin	Dua belas perbandingan diuji, seluruhnya memberi p Holm 1,0000.
Encoder yang dilatih lebih baik daripada yang dibekukan	Arahnya berbeda antar arsitektur, dan tidak satu pun perbandingannya lolos koreksi Holm.
Sebagian besar hasil terbitan pada Fake-or-Real memakai split acak	Terbantah. Setidaknya satu penelitian terverifikasi memakai partisi resmi yang pembicaranya terpisah [20].

Enam butir di atas adalah yang paling berpengaruh terhadap kesimpulan. Tujuh butir lain yang lebih kecil tercatat pada berkas hasil di repositori. Seluruh penarikan ini berasal dari satu sebab yang sama, yaitu menyimpulkan sebelum ragam antar inisialisasi diukur.

8. Kesimpulan

Penelitian ini mengaudit ulang deteksi suara palsu buatan mesin pada dataset Fake-or-Real dan memperoleh tiga hasil yang bertahan setelah diuji. Pertama, riwayat kompresi berkas berkorelasi hampir sempurna dengan label pada partisi latih dan validasi lalu hilang pada partisi uji, sehingga sebagian isyarat yang dipelajari model bukan jejak sintesis melainkan riwayat berkas. Kedua, selisih besar yang biasa dikaitkan dengan protokol pembagian data sebagian besar berasal dari letak ambang keputusan, dan daya pisah model sebenarnya bertahan. Ketiga, sebagian besar selisih antar konfigurasi tidak melampaui ragam antar inisialisasi acak, sehingga tidak dapat dinyatakan sebagai perbaikan.

Yang tidak dapat disimpulkan juga perlu dinyatakan. Penelitian ini tidak menemukan arsitektur atau augmentasi yang terbukti lebih baik daripada yang lain pada ukuran sampel yang tersedia. Selisih yang bertahan hanyalah yang berukuran puluhan poin, dan seluruhnya berasal dari kesalahan konfigurasi yang diperbaiki, bukan dari kebaruan metode.

Arah lanjutan yang paling berguna karena itu bukan arsitektur baru, melainkan prosedur pelaporan. Menjalankan tiap konfigurasi beberapa kali dan mencantumkan simpangan bakunya lebih mengubah kesimpulan bidang ini daripada menambah satu lapisan pada model.

Ketersediaan data dan kode

Seluruh kode, berkas hasil, dan skrip yang menghasilkan tiap angka dan tiap gambar pada naskah ini tersedia di repositori penelitian. Tiap tabel dan tiap gambar dapat dibangun ulang dengan satu perintah. Dataset Fake-or-Real tersedia dari penerbitnya, dan bobot model tidak disertakan karena ukurannya.

Daftar pustaka

- [1] M. Li dkk., "Audio Anti-Spoofing Detection: A Survey", 2024. arXiv:2404.13914.
- [2] A. Khan dkk., "Voice Spoofing Countermeasures: Taxonomy, State-of-the-Art, Experimental Analysis of Generalizability, Open Challenges, and the Way Forward", 2022. arXiv:2210.00417.
- [3] J. Yamagishi dkk., "ASVspoof 2021: Accelerating Progress in Spoofed and Deepfake Speech Detection", dalam Proc. ASVspoof Workshop, 2021. arXiv:2109.00537.
- [4] H. Delgado dkk., "ASVspoof 2021: Automatic Speaker Verification Spoofing and Countermeasures Challenge Evaluation Plan", 2021. arXiv:2109.00535.
- [5] X. Liu dkk., "ASVspoof 2021: Towards Spoofed and Deepfake Speech Detection in the Wild", IEEE/ACM Trans. Audio, Speech, and Language Processing, 2023. arXiv:2210.02437.
- [6] X. Wang dkk., "ASVspoof 5: Crowdsourced Speech Data, Deepfakes, and Adversarial Attacks at Scale", dalam Proc. ASVspoof Workshop, 2024. arXiv:2408.08739.
- [7] R. Reimao dan V. Tzerpos, "FoR: A Dataset for Synthetic Speech Detection", dalam Proc. International Conference on Speech Technology and Human-Computer Dialogue (SpeD), 2019.
- [8] N. M. Müller, P. Czempin, F. Dieckmann, A. Froghyar dan K. Böttinger, "Does Audio Deepfake Detection Generalize?", dalam Proc. Interspeech, 2022, hlm. 2783-2787.
- [9] J. Jung dkk., "SpoofCeleb: Speech Deepfake Detection and SASV In The Wild", 2024. arXiv:2409.17285.
- [10] H. Kim dkk., "Beyond Silence: Bias Analysis through Loss and Asymmetric Approach in Audio Anti-Spoofing", 2024. arXiv:2406.17246.
- [11] R. Geirhos dkk., "Shortcut Learning in Deep Neural Networks", Nature Machine Intelligence, vol. 2, hlm. 665-673, 2020.
- [12] A. Torralba dan A. A. Efros, "Unbiased Look at Dataset Bias", dalam Proc. IEEE Conference on Computer Vision and Pattern Recognition, 2011.
- [13] "How Well Do Current Speech Deepfake Detection Methods Generalize to the Real World?", 2026. arXiv:2603.05852.
- [14] "When EER Hides Deployment Failure: Auditing Threshold Transfer and Unlabeled Score Calibration for Speech Deepfake Detectors", 2026. arXiv:2606.21584.
- [15] C. Guo, G. Pleiss, Y. Sun dan K. Q. Weinberger, "On Calibration of Modern Neural Networks", dalam Proc. International Conference on Machine Learning, 2017. arXiv:1706.04599.
- [16] X. Bouthillier dkk., "Accounting for Variance in Machine Learning Benchmarks", dalam Proc. Machine Learning and Systems (MLSys), 2021. arXiv:2103.03098.
- [17] X. Wang dkk., "ASVspoof 5: Design, Collection and Validation of Resources for Spoofing, Deepfake, and Adversarial Attack Detection Using Crowdsourced Speech", 2025. arXiv:2502.08857.
- [18] J. Yi dkk., "ADD 2022: The First Audio Deep Synthesis Detection Challenge", dalam Proc. ICASSP, 2022. arXiv:2202.08433.
- [19] N. M. Müller dkk., "Harder or Different? Understanding Generalization of Audio Deepfake Detection", dalam Proc. Interspeech, 2024.
- [20] S. Ahmad, M. Ahmed dan S. Imtiaz, "Classical Machine Learning Baselines for Deepfake Audio Detection on the Fake-or-Real Dataset", Clarkson University, 2026. arXiv:2604.13400.
- [21] "Hybrid CNN-LSTM Architectures for Deepfake Audio Detection Using MFCC and Spectrogram Analysis", American Journal of Mathematical and Computer Modelling, vol. 10, no. 3, 2025.
- [22] K. Bhagtani dkk., "MFAAN: Unveiling Audio Deepfakes with a Multi-Feature Authenticity Network", 2023. arXiv:2311.03509.
- [23] A. Baevski, H. Zhou, A. Mohamed dan M. Auli, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations", dalam Advances in Neural Information Processing Systems, 2020. arXiv:2006.11477.

- [24] W.-N. Hsu dkk., "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units", *IEEE/ACM Trans. Audio, Speech, and Language Processing*, vol. 29, hlm. 3451-3460, 2021. arXiv:2106.07447.
- [25] S. Chen dkk., "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing", *IEEE Journal of Selected Topics in Signal Processing*, vol. 16, no. 6, hlm. 1505-1518, 2022. arXiv:2110.13900.
- [26] H. Tak, M. Todisco, X. Wang, J. Jung, J. Yamagishi dan N. Evans, "Automatic Speaker Verification Spoofing and Deepfake Detection Using wav2vec 2.0 and Data Augmentation", dalam *Proc. Odyssey*, 2022. arXiv:2202.12233.
- [27] H. Tak, J. Patino, M. Todisco, A. Nautsch, N. Evans dan A. Larcher, "End-to-End Anti-Spoofing with RawNet2", dalam *Proc. ICASSP*, 2021. arXiv:2011.01108.
- [28] J. Jung dkk., "AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks", dalam *Proc. ICASSP*, 2022. arXiv:2110.01200.
- [29] T. Liu dkk., "Nes2Net: A Lightweight Nested Architecture for Foundation Model Driven Speech Anti-Spoofing", *IEEE Trans. Information Forensics and Security*, 2025. arXiv:2504.05657.
- [30] Y. Gong, Y.-A. Chung dan J. Glass, "AST: Audio Spectrogram Transformer", dalam *Proc. Interspeech*, 2021. arXiv:2104.01778.
- [31] K. Okabe, T. Koshinaka dan K. Shinoda, "Attentive Statistics Pooling for Deep Speaker Embedding", dalam *Proc. Interspeech*, 2018. arXiv:1803.10963.
- [32] Y. Kwak dkk., "Towards Scalable AASIST: Refining Graph Attention for Speech Deepfake Detection", 2025. arXiv:2507.11777.
- [33] K. Borodin dkk., "WavLM Model Ensemble for Audio Deepfake Detection", 2024. arXiv:2408.07414.
- [34] H. Tak, M. Kamble, J. Patino, M. Todisco dan N. Evans, "RawBoost: A Raw Data Boosting and Augmentation Method Applied to Automatic Speaker Verification Anti-Spoofing", dalam *Proc. ICASSP*, 2022.
- [35] "A Comparison of SSL-Based Feature Extractors and Back-End Classifiers for Spoofing Detection: A Multi-Corpus Training and Cross-Linguistic Analysis", 2026. arXiv:2606.08669.
- [36] "DeePen: Penetration Testing for Audio Deepfake Detection", 2025. arXiv:2502.20427.
- [37] "CodecFake+: Codec-Based Resynthesized Data as a Proxy for Detecting CodecFake Speech", 2025. arXiv:2501.08238.
- [38] "Linguistic Bias Mitigation for Spoofing Detection via Gradient Reversal and a Variational Information Bottleneck", 2026. arXiv:2606.31411.
- [39] J. P. A. Ioannidis, "Why Most Published Research Findings Are False", *PLoS Medicine*, vol. 2, no. 8, e124, 2005.
- [40] S. Holm, "A Simple Sequentially Rejective Multiple Test Procedure", *Scandinavian Journal of Statistics*, vol. 6, no. 2, hlm. 65-70, 1979.
- [41] Y. Benjamini dan Y. Hochberg, "Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing", *Journal of the Royal Statistical Society B*, vol. 57, no. 1, hlm. 289-300, 1995.
- [42] J. Demšar, "Statistical Comparisons of Classifiers over Multiple Data Sets", *Journal of Machine Learning Research*, vol. 7, hlm. 1-30, 2006.
- [43] B. Recht, R. Roelofs, L. Schmidt dan V. Shankar, "Do ImageNet Classifiers Generalize to ImageNet?", dalam *Proc. International Conference on Machine Learning*, 2019.
- [44] J. Thiemann, N. Ito dan E. Vincent, "The Diverse Environments Multi-channel Acoustic Noise Database (DEMAND)", *Proceedings of Meetings on Acoustics*, vol. 19, 2013.
- [45] B. L. Welch, "The Generalization of Student's Problem when Several Different Population Variances are Involved", *Biometrika*, vol. 34, no. 1-2, hlm. 28-35, 1947.
- [46] B. A. Nosek, C. R. Ebersole, A. C. DeHaven dan D. T. Mellor, "The Preregistration Revolution", *Proceedings of the National Academy of Sciences*, vol. 115, no. 11, hlm. 2600-2606, 2018.

Lampiran A. Seluruh konfigurasi pada partisi resmi

Tabel ini memuat seluruh konfigurasi yang dijalankan minimal tiga kali pada partisi resmi, diurutkan menurut akurasi. Ia disertakan supaya pembaca dapat memeriksa bahwa angka pada bagian 4 tidak dipilih untuk menguntungkan kesimpulan.

Arsitektur	Augmentasi dan konfigurasi	n	Akurasi	Simpangan baku
wavlm	fullbgrb_b16e10	3	98,90	0,18
wavlm	fullbgD6_b16e10	3	98,71	0,64
wavlm	fullbg_b16e10	3	98,65	0,37
wavlm	fullbgN12_b16e10	3	98,65	1,25
nes2net	fullrb_b16e10	3	98,50	0,41
wavlm	fullbgD1_b16e10	3	98,44	0,69
wavlm	full_b16e10	5	98,36	0,63
wavlm	fullbgD3_b16e10	5	98,22	1,89
wavlm	fullbgN3_b16e10	3	97,95	0,98
nes2net	fullbgrb_b16e10	3	97,46	2,10
wavlm	fullUF_b16e10	3	97,30	1,71
hubert	codec_b16e10	8	97,29	2,16
nes2net	fullbg_b16e10	3	97,12	2,77
nes2net	soft_b16e10	3	96,75	0,77
wavlm	codec_b16e10	3	96,51	2,41
hubert	fullUF_b32e10	5	96,19	2,37
hubert	fullbg_b16e10	3	95,71	1,29
hubert	full_b16e10	3	95,34	0,88
hubert	full_b32e10	3	94,67	1,12
nes2net	full_b16e10	3	93,75	5,15
ast	proposalULRPK_b32e20	3	93,57	1,75
ast	fullUF_b32e10	3	93,38	1,85
cnn_asp	none_b32e10	3	92,56	3,72
cnn_asp	codecAV_b32e10	3	92,28	2,96
cnn_asp	codec (gaya lama, tanpa konfigurasi pada nama)	3	91,94	3,50
ast	proposalULR_b32e20	3	90,50	1,75
ast	full_b32e10	3	89,15	3,49
ast	proposal_b32e10	5	86,75	4,41
ast	proposal_b32e20	5	77,52	5,83
wavlm	proposalULRPK_b16e20	5	63,29	4,19
hubert	proposalULRPK_b32e20	5	51,64	6,47